




Bioinformática

Introdução a Modelagem

Barretos, 2025



Análise Estatística



Descritiva

Descrever uma coletividade dada, sem objetivo de generalizar as conclusões.

Inferencial

Baseando-se no estudo das amostras, chegar a **conclusões** que dizem respeito a população





FIGURA 1 Processo de modelagem



O que é um modelo ?





Função:
Se uma variável y
depende de uma variável
 x de tal modo que cada
valor de x determina
exatamente um valor de
 y , então dizemos que y é
função de x




Função:


Se uma variável
depende de uma
 x de tal modo que
valor de x determi
exatamente um
 y , então dizemos
função de x









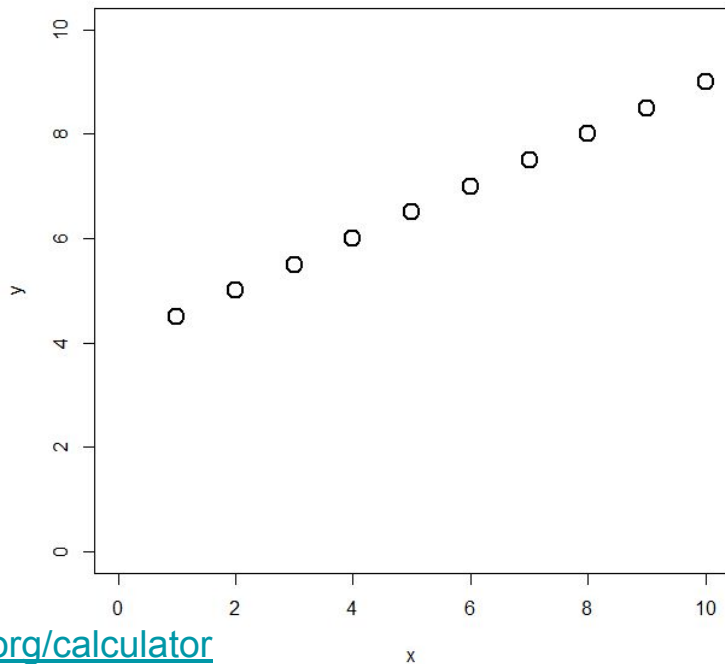




x

$$f(x) = a + b \cdot x$$

y







x

$$f(x) = a + b \cdot x$$


y




Determinístico



Aleatório (probabilístico)







Desvios

$$y - f(x) =$$



Desvios

$$y - f(x) =$$
$$= y - [a + b \cdot x]$$




Desvios

$$\begin{aligned} y - f(x) &= \\ &= y - [a + b \cdot x] \\ \epsilon &= (y - a - b \cdot x) \end{aligned}$$



$$y = a + b \cdot x + \epsilon$$





Regressão Linear Simples



Modelo de Regressão Linear Simples

$$y = a + b \cdot x + \epsilon$$

$$y = \beta_0 + \beta_1 \cdot x + \epsilon$$

$$y = \alpha + \beta \cdot x + \epsilon$$



Modelo de Regressão Linear Simples

$$y = a + b \cdot x + \epsilon$$

$$y = \beta_0 + \beta_1 \cdot x + \epsilon$$

Parâmetros

$$y = \alpha + \beta \cdot x + \epsilon$$



Observation, i	Response, y	Regressor
		x_1
1	y_1	x_{11}
2	y_2	x_{21}
\vdots	\vdots	\vdots
n	y_n	x_{n1}



Estimação dos parâmetros



Modelo de regressão populacional

$$y = \beta_0 + \beta_1 x + \varepsilon$$



Modelo de regressão populacional

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Modelo de regressão amostral

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$



Modelo de Regressão Linear Simples


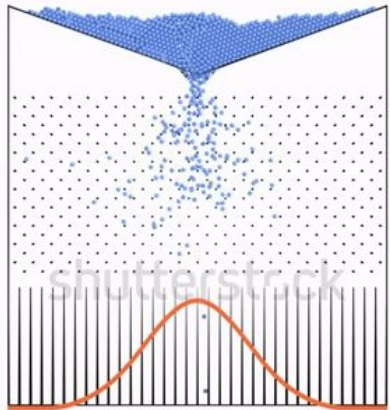
$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$



Modelo de Regressão Linear Simples

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

$$\epsilon_i \sim N(0, \sigma^2)$$





O modelo que mais se aproxima dos dados (verossímil)



Estimar os parâmetros

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

$$\epsilon_i \sim N(0, \sigma^2)$$



Métodos de estimação

1. Mínimos quadrados (*least-squares*);
2. Máxima verossimilhança (*maximum likelihood*);



Métodos de estimação

1. Mínimos quadrados (*least-squares*);
2. Máxima verossimilhança (*maximum likelihood*);

Conhecimentos a priori:


Matemática algébrica (somatória)


Cálculo diferencial (derivada)

Probabilidade (função de densidade de probabilidade)



Contextualização didática







Desvios

Modelo de regressão populacional

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Modelo de regressão amostral

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$e_i = y_i - \hat{y}_i$$



Desvios

Modelo de regressão populacional

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Modelo de regressão amostral

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\begin{aligned} e_i &= y_i - \hat{y}_i \\ &= y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \end{aligned}$$



Desvios

Modelo de regressão populacional

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Modelo de regressão amostral

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\begin{aligned} e_i &= y_i - \hat{y}_i \\ &= y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \end{aligned}$$

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$




$$\left. \frac{\partial S}{\partial \beta_0} \right|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\left. \frac{\partial S}{\partial \beta_1} \right|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0$$

$$\left. \frac{\partial S}{\partial \beta_0} \right|_{\hat{\beta}_0, \hat{\beta}_1}$$

$$\left(\beta_1 x_i \right) = 0$$




$$\left. \frac{\partial S}{\partial \beta_1} \right|_{\hat{\beta}_0, \hat{\beta}_1}$$

$$\left(x_i \right) x_i = 0$$



Equação Matemática

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$





Equação Matemática

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n y_i x_i - \frac{\left(\sum_{i=1}^n y_i\right)\left(\sum_{i=1}^n x_i\right)}{n}}{\sum_{i=1}^n x_i^2 - \frac{\left(\sum_{i=1}^n x_i\right)^2}{n}}$$



Equação Matemática

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$



Equação Matemática

$$SS_{\text{Res}} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\hat{\sigma}^2 = \frac{SS_{\text{Res}}}{n - 2} = MS_{\text{Res}}$$



Prática 1






Regressão Linear Múltipla



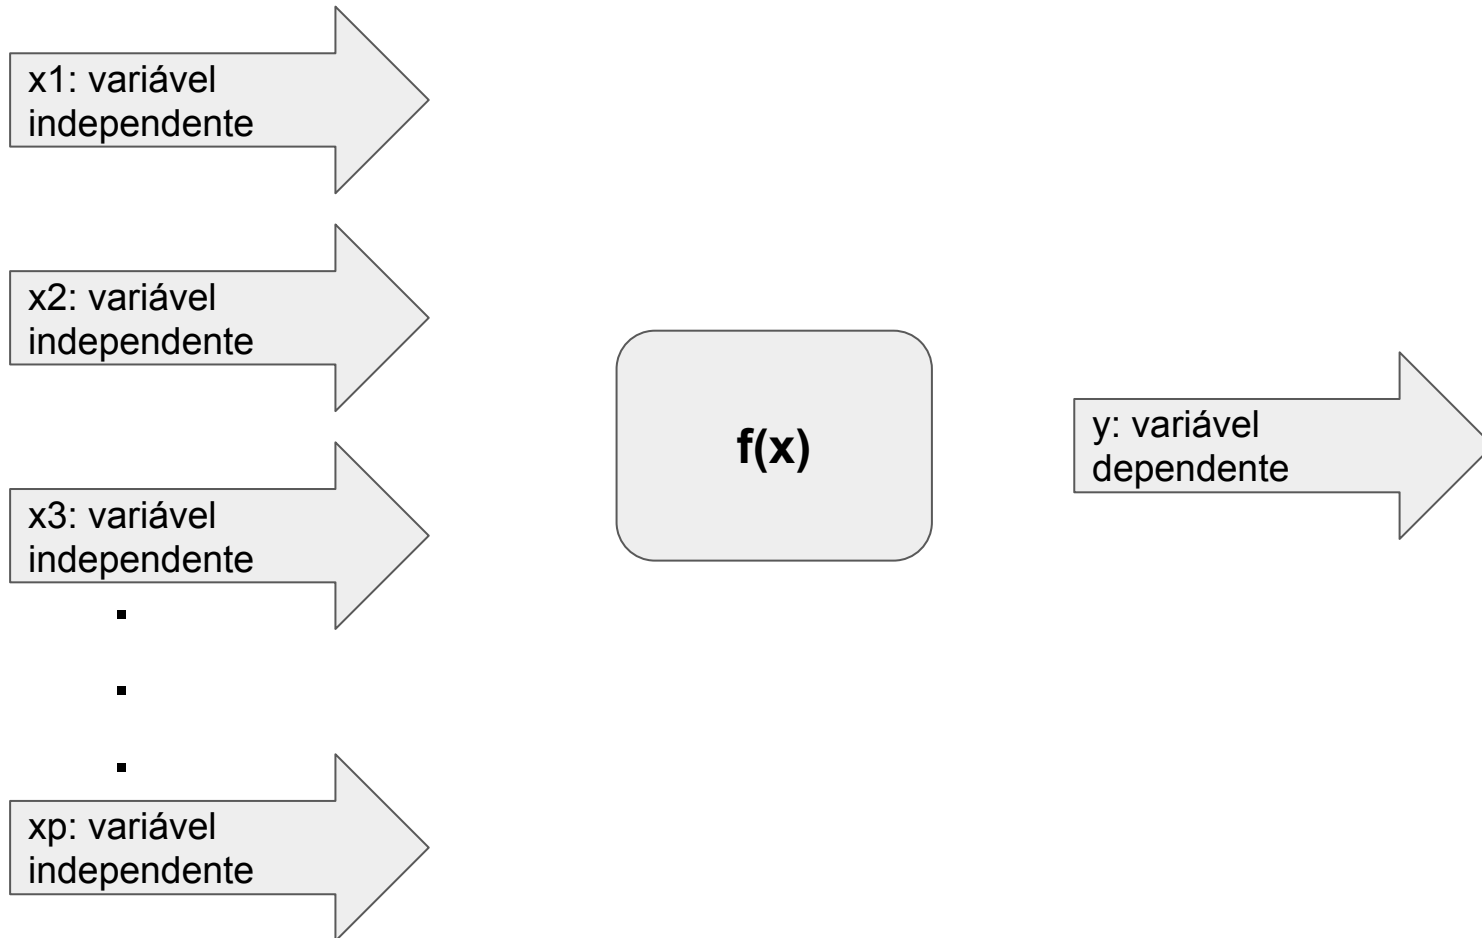
x1: variável
independente

$f(x)$

y: variável
dependente









Modelo de Regressão Múltipla

$$y = \beta_0 + \beta_1 \cdot x + \epsilon$$

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \epsilon$$

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_3 + \epsilon$$

▪
▪
▪

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_3 + \dots + \beta_p \cdot x_p + \epsilon$$



Modelo de Regressão Múltipla

$$y = \beta_0 + \beta_1 \cdot x + \epsilon$$

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \epsilon$$

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_3 + \epsilon$$

▪
▪
▪

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_3 + \dots + \beta_p \cdot x_p + \epsilon$$

O modelo ajustado é mais complicado, porém os princípios básicos são os mesmos da **regressão simples**.



$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon_i$$



Observation, i	Response, y	Regressors			
		x_1	x_2	\dots	x_k
1	y_1	x_{11}	x_{12}	\dots	x_{1k}
2	y_2	x_{21}	x_{22}	\dots	x_{2k}
\vdots	\vdots	\vdots	\vdots		\vdots
n	y_n	x_{n1}	x_{n2}	\dots	x_{nk}



Revisão Matrizes



Matriz

$$\mathbf{A} = \begin{pmatrix} 65 & 154 \\ 73 & 182 \\ 68 & 167 \end{pmatrix}.$$



Matriz

- Variável que pode armazenar n informações;
- Estrutura n dimensional;
- Homogênea.

$$\mathbf{A} = \begin{pmatrix} 65 & 154 \\ 73 & 182 \\ 68 & 167 \end{pmatrix}$$



Notação matemática

$$\mathbf{A} = (a_{ij}) = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \end{pmatrix} \quad \mathbf{A} = \begin{pmatrix} 65 & 154 \\ 73 & 182 \\ 68 & 167 \end{pmatrix}$$



$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & & \vdots \\ a_{k1} & a_{k2} & \dots & a_{kp} \end{pmatrix}$$



Matriz - Identidade

$$\mathbf{I} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$



Operações Básicas - Transposição de Matriz

$$\mathbf{A} = \begin{pmatrix} 6 & -2 \\ 4 & 7 \\ 1 & 3 \end{pmatrix}, \quad \mathbf{A}' = \begin{pmatrix} 6 & 4 & 1 \\ -2 & 7 & 3 \end{pmatrix}.$$



Operações Básicas - Soma

$$\begin{pmatrix} 7 & -3 & 4 \\ 2 & 8 & -5 \end{pmatrix} + \begin{pmatrix} 11 & 5 & -6 \\ 3 & 4 & 2 \end{pmatrix} = \begin{pmatrix} 18 & 2 & -2 \\ 5 & 12 & -3 \end{pmatrix}$$

Operações Básicas - Multiplicação



$$\mathbf{AB} = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix} \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{pmatrix}$$

$$= \begin{pmatrix} a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31} & a_{11}b_{12} + a_{12}b_{22} + a_{13}b_{32} \\ a_{21}b_{11} + a_{22}b_{21} + a_{23}b_{31} & a_{21}b_{12} + a_{22}b_{22} + a_{23}b_{32} \end{pmatrix}$$

Operações Básicas - Multiplicação



$$\begin{aligned}
 \mathbf{AB} &= \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix} \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{pmatrix} \\
 &= \begin{pmatrix} a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31} & a_{11}b_{12} + a_{12}b_{22} + a_{13}b_{32} \\ a_{21}b_{11} + a_{22}b_{21} + a_{23}b_{31} & a_{21}b_{12} + a_{22}b_{22} + a_{23}b_{32} \end{pmatrix}
 \end{aligned}$$

Operações Básicas - Multiplicação



$$\begin{aligned}
 \mathbf{AB} &= \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix} \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{pmatrix} \\
 &= \begin{pmatrix} a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31} & a_{11}b_{12} + a_{12}b_{22} + a_{13}b_{32} \\ a_{21}b_{11} + a_{22}b_{21} + a_{23}b_{31} & a_{21}b_{12} + a_{22}b_{22} + a_{23}b_{32} \end{pmatrix}
 \end{aligned}$$

Operações Básicas - Multiplicação



$$\begin{aligned}
 \mathbf{AB} &= \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix} \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{pmatrix} \\
 &= \begin{pmatrix} a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31} & a_{11}b_{12} + a_{12}b_{22} + a_{13}b_{32} \\ a_{21}b_{11} + a_{22}b_{21} + a_{23}b_{31} & a_{21}b_{12} + a_{22}b_{22} + a_{23}b_{32} \end{pmatrix}
 \end{aligned}$$



Operações Básicas - Multiplicação

$$\mathbf{A} = \begin{pmatrix} 2 & 1 & 3 \\ 4 & 6 & 5 \end{pmatrix}$$

$$\mathbf{B} = \begin{pmatrix} 1 & 4 \\ 2 & 6 \\ 3 & 8 \end{pmatrix}.$$

$$\begin{aligned} \mathbf{AB} &= \begin{pmatrix} 2 \cdot 1 + 1 \cdot 2 + 3 \cdot 3 & 2 \cdot 4 + 1 \cdot 6 + 3 \cdot 8 \\ 4 \cdot 1 + 6 \cdot 2 + 5 \cdot 3 & 4 \cdot 4 + 6 \cdot 6 + 5 \cdot 8 \end{pmatrix} \\ &= \begin{pmatrix} 13 & 38 \\ 31 & 92 \end{pmatrix} \end{aligned}$$



Operações Básicas - Multiplicação

$$A = \begin{bmatrix} 2 & 3 \\ 4 & 5 \end{bmatrix} \quad I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$A \cdot I = \begin{bmatrix} 2 \cdot 1 + 3 \cdot 0 & 2 \cdot 0 + 3 \cdot 1 \\ 4 \cdot 1 + 5 \cdot 0 & 4 \cdot 0 + 5 \cdot 1 \end{bmatrix}$$



Operações Básicas - Multiplicação

$$A = \begin{bmatrix} 2 & 3 \\ 4 & 5 \end{bmatrix} \quad I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$A \cdot I = \begin{bmatrix} 2 \cdot 1 + 3 \cdot 0 & 2 \cdot 0 + 3 \cdot 1 \\ 4 \cdot 1 + 5 \cdot 0 & 4 \cdot 0 + 5 \cdot 1 \end{bmatrix}$$



Operações Básicas - Multiplicação

$$A = \begin{bmatrix} 2 & 3 \\ 4 & 5 \end{bmatrix}$$

$$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$A \cdot I = \begin{bmatrix} 2 \cdot 1 + 3 \cdot 0 & 2 \cdot 0 + 3 \cdot 1 \\ 4 \cdot 1 + 5 \cdot 0 & 4 \cdot 0 + 5 \cdot 1 \end{bmatrix}$$



Operações Básicas - Multiplicação

Ela não é comutativa.

A frase “a ordem do fator não altera o produto”

$$\mathbf{AB \neq BA.}$$



Operações Básicas - Inversa de Matriz

Pra que serve uma operação inversa ???

Escalar (“números”)

Inversa da soma

$$1 + ??? = 0 \text{ (neutro da soma)}$$

Inverso da multiplicação

$$2 * ??? = 1 \text{ (neutro da multiplicação)}$$



Operações Básicas - Inversa de Matriz

Pra que serve uma operação inversa ???

Escalar (“números”)

Inversa da soma

$$1 + (-1) = 0 \text{ (neutro da soma)}$$

Inverso da multiplicação

$$2 * \frac{1}{2} = \frac{2}{2} = 1 \text{ (neutro da multiplicação)}$$



Operações Básicas - Inversa de Matriz

E pra isso, temos a inversa da multiplicação de matriz

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$$



Voltando ...



Observation, i	Response, y	Regressors			
		x_1	x_2	\dots	x_k
1	y_1	x_{11}	x_{12}	\dots	x_{1k}
2	y_2	x_{21}	x_{22}	\dots	x_{2k}
\vdots	\vdots	\vdots	\vdots		\vdots
n	y_n	x_{n1}	x_{n2}	\dots	x_{nk}



Cálculo Matemática

$$y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \cdots + \beta_k x_{1k} + \varepsilon_1$$

$$y_2 = \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \cdots + \beta_k x_{2k} + \varepsilon_2$$

$$\vdots$$

$$y_n = \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \cdots + \beta_k x_{nk} + \varepsilon_n$$



Cálculo Matemática

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$



Cálculo Matemática

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$



Cálculo Matemática

Modelo de regressão populacional

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Modelo de regressão amostral

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$



Cálculo Matemática - Matricial

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$$



Cálculo Matemática

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{H}\mathbf{y}$$

$$\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$$



$$SS_{\text{Res}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2 = \mathbf{e}'\mathbf{e}$$

$$MS_{\text{Res}} = \frac{SS_{\text{Res}}}{n - p}$$



Prática 2





Considerações finais

1. Tudo é feito com 1 linha de código;



Considerações finais

1. Tudo é feito com 1 linha de código;
2. Operações matriciais são muito importantes para a estatística;
 - a. Interpretações biológicas



Cálculo Matemática

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$



- Observações independentes;
- Sem correlação
- Variância constante (homogeneidade)

$$\begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} \quad \varepsilon_i \sim N(0, \sigma^2)$$

$$\begin{bmatrix} \sigma^2 & 0 & 0 & 0 & 0 \\ 0 & \sigma^2 & 0 & 0 & 0 \\ 0 & 0 & \sigma^2 & 0 & 0 \\ 0 & 0 & 0 & \sigma^2 & 0 \\ 0 & 0 & 0 & 0 & \sigma^2 \end{bmatrix}$$



- Observações são correlacionadas por um grupo (simetria composta);
- Variância constante (homogeneidade)

$$\begin{bmatrix} \sigma^2 + \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma^2 + \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma_s^2 & \sigma^2 + \sigma_s^2 & \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma^2 + \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma^2 + \sigma_s^2 \end{bmatrix}$$



- Observações são correlacionadas por um grupo (simetria composta);
- Variância constante (homogeneidade)

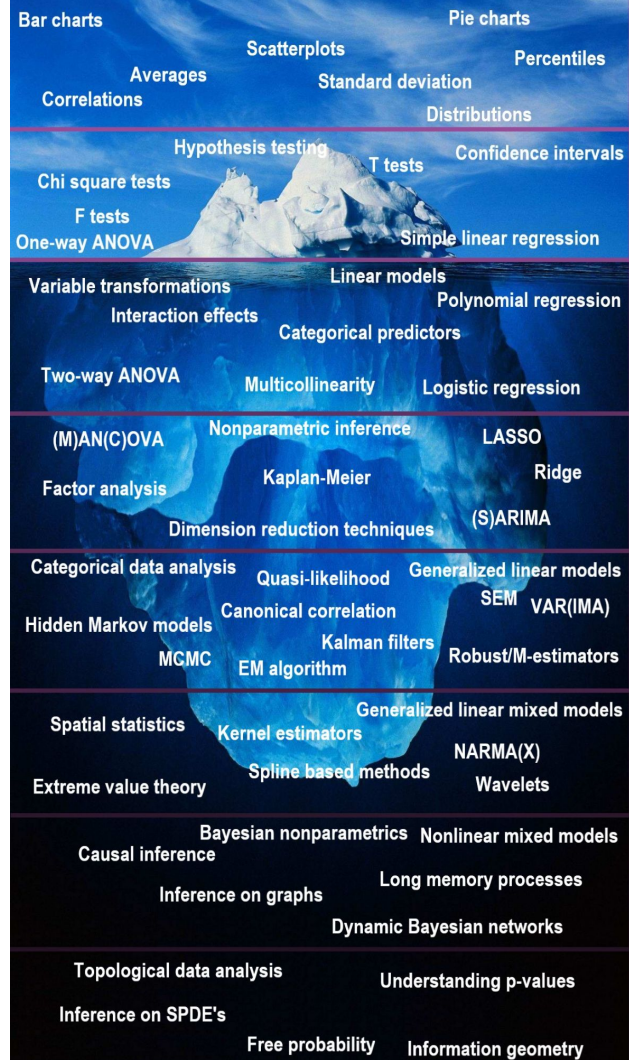
Modelos de efeitos mistos

$$\begin{bmatrix} \sigma^2 + \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma^2 + \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma_s^2 & \sigma^2 + \sigma_s^2 & \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma^2 + \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma_s^2 & \sigma^2 + \sigma_s^2 \end{bmatrix}$$



Considerações finais

1. Tudo é feito com 1 linha de código;
2. Operações matriciais são muito importantes para a estatística;
 - a. Interpretações biológicas
3. Apenas um *nutshell*





Estatística - Regressão linear múltiplo

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$$

Ciência de dados - Regressão Ridge

$$\hat{\boldsymbol{\beta}}_{\text{R}} = (\mathbf{X}'_{\text{A}}\mathbf{X}_{\text{A}})^{-1} \mathbf{X}'_{\text{A}}\mathbf{y}_{\text{A}} = (\mathbf{X}'\mathbf{X} + k\mathbf{I}_p)^{-1} \mathbf{X}'\mathbf{y}$$



Estatística - Regressão
linear múltiplo

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$$

Ciência de dados - Regressão Ridge

$$\hat{\beta}_R = (\mathbf{X}'_A \mathbf{X}_A)^{-1} \mathbf{X}'_A \mathbf{y}_A = (\mathbf{X}'\mathbf{X} + k\mathbf{I}_p)^{-1} \mathbf{X}'\mathbf{y}$$

Ciência de dados - Suporte vetor máquina

$$\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$$

$$\mathbf{H}\hat{\beta} = (\mathbf{H}\mathbf{H}^T + \lambda\mathbf{I})^{-1}\mathbf{H}\mathbf{H}^T\mathbf{y}.$$

$$\text{kernel } \{\mathbf{H}\mathbf{H}^T\}_{i,i'} = K(x_i, x_{i'})$$



Considerações finais

1. Tudo é feito com 1 linha de código;
2. Operações matriciais são muito importantes para a estatística;
 - a. Interpretações biológicas
3. Apenas um *nutshell*;
4. **Não tenham medo da matemática, atualmente podemos testar muita coisa !!!**



Referência (matemática)

